
SIGAIs 2025 聴講レポート

学籍番号: 82518829 氏名: 戸倉 健登

1. 講演を聴講しての感想

Transformer が転機となったことは理解していたが、講演を通して、その後に国内で LLM.jp のような組織が立ち上がる流れを把握できた。大規模言語モデルは地域固有の知識を十分にに取り込む必要があり、汎用モデルだけでは不十分であること、さらに地政学的リスクへの備えとして先端技術を自国でも扱える体制づくりが重要であるという指摘が印象的だった。最先端そのものを追う必要はなくとも、「自分たちで動かせる最新技術」を確保しておくことの重要性が語られた。

日本語は 2 文字で 1 トークンになるため、数兆規模の学習データが必要となる一方、ネット上で得られる日本語コーパスは約 1 兆トークンに留まるという現実も示された。この状況が、国産 LLM 開発の難しさと必要性の双方を裏付けている。

LLM.jp は、国産モデルをつくるだけでなく、オープンソース開発やデータ公開を中心的な活動としており、ライセンスは Apache を採用している。研究現場では LLM を使う場面が増えているが、日本語に強いモデルが不可欠なケースは多く、こうした基盤を国内で整備する意義は大きいと感じた。

ずだ。早期にその基盤が整備されることを期待したい。

2. 自分としての意見

国産 LLM の取り組みは、技術的自立の観点だけでなく、研究・産業双方の基盤拡充という意味でも重要だと考える。特に日本語固有の表現や文化的背景を適切に扱えるモデルが増えることは、研究者だけでなく一般ユーザにとっても恩恵が大きい。さらに、学習データやモデル構造を公開していく姿勢は、国内コミュニティの水準を底上げし、透明性のある議論を促す点で評価できる。

3. 批判的な意見

一方で、学習用データと実際のアプリケーションで必要とされるデータ分布を一致させるのは難しそうだと感じた。利用者が具体的に何を LLM に求め、日本語特有の知識がどこで必要になるのかを明確化できなければ、収集すべきコーパスの設計も曖昧になる。単に大量の日本語データを集めるだけでは不十分で、他言語では補えない固有知識をどう定義するかが重要になると思う。

また、オープンソース化は意義が大きい一方で、外部の企業が性能向上のためにデータを無制限に取り込むモデルを作り、結果として国内が培った資源が他者に大きく利用されるリスクもある。公的資金で運営する以上、日本の利用者に明確な利益が返る仕組みや、学習データの扱いに関する公平性を担保する枠組みが求められる。

さらに、現状ではデータ透明性が自主的な申告に依存しており、制度的に監査・開示を担保する仕組みは未成熟に見える。学習データの管理・公開を技術的に支援するシステムが整わない限り、倫理指針の運用や資金投入の基準作りは難しくなるは